Du repérage à l'analyse : un modèle NER pour l'analyse des entités nommées dans les textes littéraires

MAUREL, Perrine
perrine-maurel@sorbonne-universite.fr
Sorbonne Université

AMALVY, Arthur
arthur.amalvy@univ-avignon.fr
Université d'Avignon

LABATUT, Vincent
vincent.labatut@univ-avignon.fr
Université d'Avignon

ALRAHABI, Motasem
motasem.alrahabi@sorbonne-universite.fr
Sorbonne Université

Reconnaissance d'entités nommées

La reconnaissance d'entités nommées (REN) en littérature, issue du Traitement Automatique des Langues naturelles (TAL), doit tenir compte de la complexité des textes : ambiguïté, richesse stylistique et entités fictives ou symboliques. La REN utilise des méthodes basées sur des règles ou l'apprentissage automatique. Les modèles profonds, notamment les Transformers comme BERT (Devlin *et al.*, 2019), CamemBERT (Martin *et al.*, 2020) et FlauBERT (Le *et al.*, 2020), améliorent la prise en compte du contexte et des spécificités linguistiques, mais nécessitent de grands corpus annotés.

Certains travaux ont exploré les entités nommées dans les textes littéraires. Bamman, Popat et Shen (2019) annotent des extraits de romans en anglais (environ 2 000 mots). Dekker *et al.* (2019) analysent des chapitres de romans classiques et modernes en anglais, se concentrant sur des extraits de 300 phrases. Frontini *et al.* (2021) étudient des passages de 400 mots pour chaque langue du corpus ELTeC. Kababgi *et al.* (2024) se penchent sur 9 062 phrases issues de six romans suisses allemands, ciblant les entités spatiales non-nommées. Ces corpus sont partiellement annotés, généralement sur des extraits plutôt que sur des textes complets, ce qui limite leur exploitation en prenant en compte la longueur considérable de ces textes.

Afin de pallier cette limitation, nous constituons un corpus de romans en français que nous annotons intégralement en entités nommées. Nous démontrons son utilité en développant un nouveau modèle neuronal optimisé pour la REN en contexte littéraire, particulièrement pour les textes longs.

Corpus proposé

Notre étude se concentre sur sept romans français des XIXe et début XXe siècles, sélectionnés pour leur richesse narrative et représentativité littéraire. Ces œuvres, issues de Wikisource , totalisent 1 320 734 tokens et illustrent une narration mêlant intrigue et description, typique du roman du XIXe siècle. Le tableau suivant contient la liste de ces romans avec, pour chacun, son auteur, année de publication, et nombre de tokens.

Roman	Auteur	Année de publication	Nombre de tokens
Les Trois Mousquetaires	Alexandre Dumas	1849	294 989
Le Rouge et le Noir	Stendhal	1854	216 445
Eugénie Grandet	Honoré de Balzac	1855	80 659
Germinal	Émile Zola	1885	220 273
Bel-Ami	Guy de Maupassant	1901	138 156
Notre-Dame de Paris	Victor Hugo	1904	221 351
Madame Bovary	Gustave Flaubert	1910	148 861

Les travaux de Sims et Bamman (2020) et d'autres chercheurs (Amalvy *et al.*, 2023; Tay et al., 2021; Labatut et Bost, 2019) soulignent les défis de l'annotation des entités nommées (EN) dans les longs textes littéraires, liés à la complexité narrative et à la résolution des coréférences. La prose littéraire, plus complexe que la prose journalistique, exige des modèles adaptés pour garantir cohérence et précision dans des tâches comme la détection de personnages et la modélisation de l'intrigue.

Processus d'annotation

Nous nous sommes basés sur le guide du projet UniversalNER (Mayhew *et al.*, 2024) pour l'annotation des entités nommées (EN), réalisée en trois phases :

- Phase exploratoire : annotation initiale d'un échantillon de textes, avec trois catégories (PER, LOC, ORG), menée par deux annotateurs par phrase. Les instructions clés sont : annoter la mention continue la plus large d'une entité nommée ; exclure les entités imbriquées et les chaînes de coréférences ; et inclure les descripteurs accompagnant les entités.
- Phase de concertation : ajustement du guide pour inclure les noms communs capitalisés (ex. "le Patron"), titres nobiliaires (ex. "Sa Majesté le roi Charles X"), déterminants (ex. "la maire"), et une nouvelle catégorie MISC pour les entités ambiguës ou indéfinies.
- Phase finale : application du guide révisé au corpus complet avec double annotation pour assurer la cohérence.

Le processus a impliqué un coordinateur et trois annotateurs. Le tableau suivant indique le nombre de mentions d'entités apparaissant dans chaque roman du corpus, par type d'entité. Le corpus produit est publiquement accessible en ligne.

Roman	Personnages	Lieux	Organisations	Divers
Les Trois Mousquetaires	8583	962	45	255
Le Rouge et le Noir	4351	806	39	78
Eugénie Grandet	1389	187	13	34
Germinal	3439	838	195	40
Bel-Ami	1773	400	25	46
Notre-Dame de Paris	3631	1409	17	94
Madame Bovary	2004	403	11	70
Total	25170	5005	345	617

Accord inter-annotateurs

L'accord inter-annotateurs, mesuré par le F1-score (96,78) et le Kappa de Cohen (93,35), montre une excellente fiabilité des annotations. Le tableau qui suit indique l'accord inter-annotateurs par type d'entité.

Classe	F1-score	Kappa
PER	97,89	93,71
LOC	87,25	75,57
ORG	95,30	86,45
MISC	75,70	47,70

Bien que l'accord global soit excellent, la classe MISC semble poser davantage de difficultés, un point que nous discutons dans la section suivante.

Difficultés rencontrées

L'annotation des EN dans les textes littéraires a posé plusieurs défis liés à la diversité des catégories, des styles et des contextes. Deux types de désaccords ont été identifiés. Les désaccords "résolvables" résultent d'oublis, d'incertitudes ou d'erreurs d'interprétation corrigibles, comme l'annotation erronée de "La Planète" en LOC au lieu d'ORG. Le second type concerne les désaccords de fond, non résolus car trop complexes ou ambigus, concernent souvent la catégorie MISC, introduite lors de la deuxième phase pour traiter ces cas spécifiques. Voici quelques exemples :

- L'énoncé "Elle s'empara d'un prie-Dieu et s'agenouilla" illustre un désaccord de fond : "prie-Dieu" peut désigner un objet (MISC) ou faire référence au divin, rendant la catégorisation ambiguë. Ce cas complexe n'a pas été tranché.
- La catégorie MISC, définie par les notions d'"indéfini" et d'"ambigu", varie selon l'interprétation des annotateurs, comme dans le cas de "l'affaire Morel", où l'hésitation porte sur son annotation en MISC ou en PER (pour "Morel" uniquement).
- L'inclusion ou l'exclusion de certains syntagmes dans les EN, comme "Français" ou "huguenots", soulève des questionnements, la capitalisation reflétant souvent des conventions typographiques plutôt qu'une intention emphatique de l'auteur.
- Les variations stylistiques entre auteurs, comme Hugo et Dumas, ont influencé l'annotation, ces derniers utilisant fréquemment des noms communs pour désigner des personnages. Dans Notre-Dame de Paris, seules 28 % des mentions d'Esmeralda utilisent des noms propres, contre 45 % pour "l'égyptienne" et 26 % pour "la bohémienne".
- Citons enfin un exemple intéressant, celui d'une référence intertextuelle dans Madame Bovary qui a influencé l'annotation : Flaubert mentionne "la Sachette" de Notre-Dame de Paris. Bien que ce nom commun ne représente

que 16 % des mentions de Paquette, sa capitalisation et son emploi ultérieur justifient son inclusion dans le guide d'annotation.

Ces cas reflètent la complexité de l'annotation des EN en littérature, exigeant des ajustements constants pour allier rigueur méthodologique et spécificités contextuelles.

Entrainement d'un nouveau modèle

Nous mettons à profit notre corpus en entraînant un modèle de REN sur celui-ci. Nous nous basons sur deux modèles CamemBERT pré-entrainés (Martin *et al.*, 2020) : l'un basé sur CamemBERT-base (100 millions de paramètres), l'autre sur CamemBERT-large (335 millions de paramètres). Nous leur ajoutons une couche neuronale de classification, et formalisons la tâche de REN comme une tâche de classification de tokens en nous basant sur le format BIO (Ramshaw et Marcus, 1995). Nous ajustons finement nos modèles sur notre corpus complet durant trois cycles d'apprentissage avec un taux d'apprentissage de 2×10^{-5} et un dropout de 0,1 (Devlin *et al.*, 2019). Pendant l'entraînement et l'inférence, le modèle prédit les entités présentes dans chaque exemple sans contexte supplémentaire. Ce modèle est disponible en ligne.

Évaluation

Afin d'évaluer la performance de notre modèle, nous procédons par validation croisée en 7 blocs : nous produisons 7 modèles différents, chacun entraîné sur un ensemble unique de 6 livres et évalué sur le livre restant. Nous utilisons la librairie seqeval en mode "défaut" pour mesurer la performance en termes de Précision, Rappel et F1-score. Le tableau suivant indique les résultats obtenus.

Roman	F1-score
Le Rouge et le Noir	91,85
Madame Bovary	91,55
Bel-Ami	91,27
Germinal	89,93
Eugénie Grandet	85,69
Notre-Dame de Paris	78,66
Les Trois Mousquetaires	66,33

Dans l'ensemble, la performance est cohérente avec les résultats obtenus précédemment par CamemBERT sur d'autres corpus français, comme sur le French Treebank (Martin et al., 2020). Deux romans semblent cependant poser plus de difficultés : "Notre-Dame de Paris" et "Les Trois Mousquetaires". Nous avons analysé manuellement les résultats et observé que le modèle rencontre des difficultés importantes à reconnaître certaines entités comme le personnage principal D'Artagnan. Cela reflète la difficulté déjà mentionnée concernant l'usage de noms communs comme substituts pour désigner certains personnages, ainsi que les observations précédentes de Dekker et al. (2019). Ces résultats sous-estiment probablement les performances du modèle final, entraîné sur l'intégralité du corpus.

Compte tenu du manque de jeux de données littéraires en français, ce modèle constitue une contribution pour la communauté en permettant une bonne performance d'inférence sur ce type de textes.

Conclusion et perspectives

Le corpus de textes littéraires, entièrement annoté, constitue une ressource essentielle développée dans cette étude. S'appuyant sur ce gold standard, nous avons également conçu un modèle de NER adapté, produisant des résultats précis malgré les défis stylistiques propres à ces œuvres.

Pour l'avenir, l'amélioration de la résolution des coréférences et l'adaptation à d'autres périodes ou langues offriront des perspectives prometteuses. Le modèle pourra également être appliqué à l'analyse des réseaux narratifs et aux outils pédagogiques en humanités numériques.

Remerciements

Nous remercions Una Faller et Romaric Parnasse qui ont participé à l'annotation du corpus.

Bibliography

Alrahabi, M., Brando, C., Frontini, F., Provenier, A., Jalabert, R., Bordry, M., Koskas, C., & Gawley, J. (2024). "Guide d'annotation manuelle d'entités nommées dans des corpus littéraires" (version 2).

Amalvy, A., Labatut, V., & Dufour, R. (2023). "The Role of Global and Local Context in Named Entity Recognition". In Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers) (pp. 714–722). Toronto, Canada: ACL.

Bamman, D., Popat, S., & Shen, S. (2019). "An Annotated Dataset of Literary Entities". In Procee-

dings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long and Short Papers) (pp. 2138–2144).

Dekker, N., Kuhn, T., & van Erp, M. (2019). "Evaluating Named Entity Recognition Tools for Extracting Social Networks from Novels". PeerJ Computer Science, 5, e189.

Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding". In Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long and Short Papers) (pp. 4171–4186).

Frontini, F., Brando, C., Byszuk, J., Galleron, I., Santos, D., & Stanković, R. (2020). "Named Entity Recognition for Distant Reading in ELTeC." In Proceedings of the CLARIN Annual Conference 2020. Virtual Event, France.

Kababgi, D., Grisot, G., Pennino, F., & Herrmann, B. (2024). "Recognising Non-Named Spatial Entities in Literary Texts: A Novel Spatial Entities Classifier." In Proceedings of the Computational Humanities Research Conference 2024 (CHR 2024) (pp. 472–481). Aarhus, Denmark.

Labatut, V., & Bost, X. (2019). "Extraction and Analysis of Fictional Character Networks: A Survey". ACM Computing Surveys, 52(5), 89.

Le, H., Vauquier, T., Antoine, J.-Y., Colin, I., Emeriau, M., & Schwab, D. (2020). "FlauBERT: Unsupervised Language Model Pre-training for French". In Proceedings of the 12th International Conference on Language Resources and Evaluation (LREC).

Martin, L., Muller, B., Suárez, P. J. O., Dupont, Y., Romary, L., de la Clergerie, É., Seddah, D., & Sagot, B. (2020). "CamemBERT: A Tasty French Language Model". In Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (pp. 7203–7219).

Mayhew, S., Blevins, T., Liu, S., Šuppa, M., Gonen, H., Imperial, J. M., Karlsson, B., Lin, P., Ljubešić, N., Miranda, L. J., Plank, B., Riabi, A., & Pinter, Y. (2024). "Universal NER: A Gold-Standard Multilingual Named Entity Recognition Benchmark". In Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers) (pp. 4322–4337).

Ramshaw, L., & Marcus, M. (1995). "Text Chunking Using Transformation-Based Learning". In Third Workshop on Very Large Corpora.

Sims, M., & Bamman, D. (2020). "Measuring Information Propagation in Literary Social Networks". In Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP) (pp. 642–652).

Tay, Y., Dehghani, M., Abnar, S., Shen, Y., Bahri, D., Pham, P., Rao, J., Yang, L., Ruder, S., & Metzler, D. (2021). "Long Range Arena: A Benchmark for Efficient Transformers". In Proceedings of the International Conference on Learning Representations.