ALMA – Wissensnetze in der Mittelalterlichen Romania Una panoramica del progetto attraverso l'edizione digitale del Libro dei cauteri

Barison, Giulia
giulia.barison@uni-saarland.de
Universität des Saarlandes, Germany

Posillipo, Yasmine
yasmin.posillipo@uni-saarland.de
Universität des Saarlandes, Germany

ALMA – Wissensnetze in der Mittelalterlichen Romania è un progetto nato nel 2022, portato avanti dall'Heidelberger Akademie der Wissenschaften (HAdW), dalla Bayerischen Akademie der Wissenschaften (BAdW) e dall'Akademie der Wissenschaften und der Literatur Mainz (AdW Mainz), e che ha come sedi di ricerca per il francese antico quella di Heidelberg, diretta dalla Dott.ssa Sabine Tittel, per l'occitano e il guascone antichi quella di Monaco, diretta dalla Prof.ssa Maria Selig, e per l'italo-romanzo antico quella di Saarbrücken, diretta dai Proff. Elton Prifti e Wolfgang Schweickard.

L'obiettivo principale di ALMA è quello di indagare le reti del sapere nel Medioevo romanzo attraverso l'interazione tra lingua e conoscenza, con un'attenzione particolare per i domini della medicina e del diritto. Tra il 1100 e il 1500 si sviluppano infatti nuove reti di conoscenza nelle lingue volgari, che vanno progressivamente a sostituire quelle tradizionali in latino. Si tratta di un cambiamento graduale e tutt'altro che lineare, che tradisce l'emergere di nuove classi sociali e un accesso sempre più ampio e socialmente eterogeneo al sapere. Quello che può sembrare un banale passaggio linguistico dal latino alle lingue volgari è in realtà il sintomo di un cambiamento che travalica i confini della lingua, e che piuttosto rappresenta una società in trasformazione, che esprime nuove esigenze in termini di trasmissione della conoscenza. Ciò che ALMA si propone di indagare è quindi in che misura a questa altezza temporale le dinamiche storiche e socio-culturali influen-

zino lo sviluppo linguistico e, viceversa, in che misura lo sviluppo linguistico interagisca con i cambiamenti storici e socio-culturali nell'ambito della diffusione del sapere. Fondamentale è quindi l'analisi delle intersezioni tra pratica comunicativa e linguaggio, e tra le reti di conoscenza e le strutture linguistiche.

Il progetto investiga i domini della medicina e del diritto nel Medioevo romanzo avvalendosi degli strumenti offerti dalla filologia testuale, dalla lessicologia, dalla lessicografia, dalla linguistica, dalla storia, dalle discipline umanistiche digitali, dal web semantico e dall'ontologia formale. Questo approccio multidisciplinare e improntato al digitale contribuisce innanzitutto all'elaborazione dei due corpora testuali multilingue, basi imprescindibili per la ricostruzione delle reti concettuali relative ai due domini della medicina e del diritto.

La costruzione dei corpora si articola su due fronti complementari: da una parte la pubblicazione di edizioni digitali di numerosi testi medievali di ambito medico e giuridico, ancora in gran parte inediti; dall'altra la conversione delle edizioni esistenti dal formato PDF a quello XML/TEI, in conformità con le linee guida TEI P5.

Ai fini dell'automatizzazione di alcune delle fasi editoriali, il progetto si avvale di strumenti basati su intelligenze artificiali (IA), come quelli messi a disposizione da Transkribus ed eScriptorium , supporti fondamentali per velocizzare il lavoro di trascrizione dei manoscritti e degli incunaboli. Nei casi in cui non siano disponibili modelli addestrati, come per alcune scritture italiane (ad es. la mercantesca e la cancelleresca), è in atto un processo di addestramento delle IA. I corpora potranno essere interrogati dall'utenza come prodotto indipendente e autonomo del progetto, offrendo uno strumento utile per ulteriori ricerche di tipo filologico e storico-linguistico. I testi inclusi nei corpora vengono tokenizzati, per dividere le singole unità lessicali, sottoposti

ad annotazione morfosintattica, per distinguere le diverse parti del discorso (Part-Of-Speech tagging – POS tagging), e lemmatizzati, per individuare i lemmi. Per queste operazioni, vengono utilizzati software esistenti di elaborazione del linguaggio naturale (Natural Language Processing – NLP), eventualmente adattati alle varietà linguistiche storiche per cui non sono stati ancora sviluppati dei modelli adeguati, come nel caso di quelle italo-romanze antiche. Infine, nella prospettiva della costruzione di nuovi modelli per il POS tagging e l' NLP , ALMA applica il più possibile un approccio collaborativo alla ricerca scientifica, improntato alla condivisione del materiale funzionale allo sviluppo di tecnologie utili all'intera comunità scientifica.

L'approccio multi- e interlinguistico, supportato dagli strumenti offerti dall'ontologia formale (Web Ontology Language – OWL), permette il superamento di un approccio sincronico e settoriale alla ricerca, favorendo una visione diacronica e comparativa dei sistemi di conoscenza, mettendo in luce la continuità tra il sapere medievale moderno, e rendendo così i risultati scientifici fruibili a un pubblico più eterogeno, anche non esclusivamente accademico.

Uno degli obiettivi del progetto è sopperire alla mancanza di rappresentazione ontologica del medioevo romanzo attraverso lo sviluppo di ontologie storicizzate dei domini di riferimento, fondate sui risultati di un'analisi onomasiologica dei testi. Tali ontologie sono concepite per l'integrazione nel Web semantico, con l'intento di offrire modelli concettuali accurati e interoperabili.

I testi dei corpora, gli articoli linguistici e la bibliografia critica (ALMABibl) saranno elaborati come Linked Open Data (LOD) in Resource Description Framework (RDF), al fine di renderli accessibili attraverso query di dati fondate sulle ontologie storicizzate. Per garantire una maggiore interoperabilità via LOD, ALMA riutilizzerà le ontologie, i dizionari e i repository di rife-

rimento per le discipline che riguardano il progetto: Onto-Lex-Lemon , lo standard de facto per rappresentare ontologie lessicali sul Web; Ontologies of Linguistic Annotation (OLiA), per la descrizione dei termini linguistici; Geonames e Getty Thesaurus of Geographic Names (TGN), per le ontologie dei toponimi; Virtual International Authority File (VIAF) e Gemeinsame Normdatei (GND), per le ontologie dei nomi di persona; e così via. L'elaborazione di LOD e di ontologie storicizzate è fondamentale anche nell'ottica di un utilizzo innovativo delle risorse lessicografiche di riferimento per l'area romanza, ovvero il Dictionnaire onomasiologique de l'ancien gascon (DAG), il Dictionnaire étymologique de l'ancien français (DEAF), il Dictionnaire de l'occitan médiéval (DOM), il Lessico Etimologico Italiano (LEI) e il Tesoro della Lingua Italiana delle Origini (TLIO).

I risultati scientifici prodotti nell'ambito del progetto ALMA verranno diffusi primariamente attraverso il portale online dedicato, concepito per essere una piattaforma interattiva di ricerca. Questo non è solo uno strumento utile per agevolare la collaborazione tra i membri di un team decentralizzato e dislocato come è quello di ALMA, ma è anche e soprattutto un mezzo fondamentale per agevolare la collaborazione tra team e una comunità scientifica più ampia, attraverso la messa a disposizione di materiale open access . Non a caso le lingue del portale online sono il tedesco, il francese e l'inglese, che favoriscono l'accessibilità a un pubblico internazionale.

In occasione della Digital Humanities Conference 2025 vorremo presentare il progetto ALMA attraverso l'edizione digitale del Libro dei cauteri , testo facente parte del corpus italo-romanzo. Il Libro dei cauteri è un interessante trattato del medico padovano Bartolomeo Squarcialupi sulla pratica della cauterizzazione al fine di ottenere la revulsione. Il trattato è conservato dal solo manoscritto Fanzago 2, I, 5, 28 della Biblioteca medica Vincenzo Pinali antica di Padova, codice illustrato della

fine del XIV o dell'inizio del XV secolo, collocabile nel padovano. Il manoscritto è diffusamente lacunoso e composito: trasmette anche una noticia anothomie e una breve sezione di un altro trattato medico non meglio identificabile. Nell'ottica della costruzione del corpus italoromanzo si è deciso di condurre un'edizione digitale sul solo Libro dei cauteri , che esporremo dalla sua progettazione, alla sua realizzazione e visualizzazione attraverso EVT 2. Verranno poi illustrati il processo di tokenizzazione, annotazione e lemmatizzazione, e gli esperimenti condotti finora su INCEpTION, Arborator-Grew, spaCy e Stanza.

Bibliography

Berners-Lee, Tim / Hendler, James / Lassila, Ora (2001): "The Semantic Web", in: *Scientific American* 284, 5: 34-43.

Bersano, Ottavia / Okinina, Nadezda (2020): "Il trattamento automatico del linguaggio applicato all'italiano volgare. La redazione di un formario tratto dalle prime dieci Lettere di Alessandra M. Strozzi", in: Marras, Cristina / Passarotti, Marco / Franzini, Greta / Litta, Eleonora (eds.): *Atti del IX Convegno Annuale dell'Associazione per l'Informatica Umanistica e la Cultura Digitale (AIUCD). La svolta inevitabile: sfide e prospettive per l'informatica umanistica. 15–17 gennaio 2020, Milano, Università Cattolica del Sacro Cuore* . Bologna: Umanistica digitale 28-33.

Bizer, Christian / Heath, Tom / Berners-Lee, Tim (2009): "Linked data. The story so far", in: *International journal on semantic web and information systems* 5, 3: 1-22.

Bozzi, Andrea (2016): "Un'ontologia per il DiTMAO (Dictionnaire des termes médico-botaniques de l'ancien occitan)", in: Trotter, David / Bozzi, Andrea / Fairon, Cédric (eds.): *Actes du XXVIIe Congrès international de linguistique et de philologie romanes (Nancy, 15–20 juillet 2013)* , Section 16: *Projets en cours ; ressources et outils nouveaux* , Nancy: Analyse et traitement informatique de la langue française (ATILF) 55-63.

Chiarcos, Christian / McCrae, John / Cimiano, Philipp / Fellbaum, Christiane (2013): "Towards open data for linguistics: lexical linked data", in: Oltramari, Alessandro / Vossen, Piek / Qin, Lu / Hovy, Eduard (eds.): *New trends of research in ontologies and lexical resources: Ideas, projects, systems* , Berlin/Heidelberg: Springer 7-25.

Cimiano, Philipp / McCrae, John P. / Buitelaar, Paul (2016): "Lexicon Model for ontologies: Community Report, 10 May 2016. Final Community Group Report 10 May 2016" ‹https://www.w3.org/2016/05/ontolex/› [23.04.2025].

Cyganiak, Richard / Wood, David / Lanthaler, Markus (2014): "RDF 1.1. concepts and abstract syntax: W3C recommendation 25 February 2014" ‹https://www.w3.org/TR/2014/REC-rdf11-concepts-20140225/› [23.04.2025].

Favaro, Manuel / Biffi, Marco / Montemagni, Simonetta (2023): "POS Tagging and Lemmatization of Historical Varieties of Languages. The Challenge of Old Italian", in: *Accademia University Press* 9, 2: 99-120.

Gandon, Fabien / Sabou, Marta / Sack, Harald (2017): "Weaving a web of linked resources", in: *Semantic web journal* 6: 1-6.

González-Blanco, Elena / Del Río, Gimena / Martínez Cantón, Clara I. (2016): "Linked Open Data to represent multilingual poetry collections. A proposal to solve interoperability issues between poetic repertoires", in: McCrae, John P. / Chiarcos, Christian / Montiel Ponsoda, Elena / Declerck, Thierry / Osenova, Petya / Hellmann, Sebastian (eds.): *Proceedings of the LREC 2016 Workshop "LDL 2016 – 5th Workshop on Linked Data in Linguistics: Managing, Building and Using Linked Language Resources", 24 May 2016 – Portorož, Slovenia* . Paris: European Language Resources Association (ELRA) 77-80.

Khan, Fahad / Bellandi, Andrea / Boschetti Federico / Monachini Monica (2017): "The challenges of converting legacy lexical resources to Linked Open Data using OntoLex-Lemon. The case of the intermediate Liddell-Scott lexicon", in: *Proceedings of the LDK 2017 Workshops: 1st Workshop on the OntoLex Model (OntoLex-2017), shared task on translation inference across dictionaries & challenges for wordnets co-located with 1st Conference*

on language, data and knowledge (LDK 2017) , 43–50 ‹https://ceur-ws.org/Vol-1899/› [23.04.2025].

McCrae, John / Montiel Ponsoda, Elena / Cimiano, Philipp (2012): "Integrating WordNet and Wiktionary with lemon", in: Chiarcos, Christian (ed.): *Linked Data in linguistics. Representing and connecting language data and language metadata* . Berlin/Heidelberg: Springer 245-334.

Moretti, Giovanni / Palmero Aprosio, Alessio (2019): "Tint 2.0: an All-inclusive Suite for NLP in Italian", in: Cabrio, Elena / Mazzei, Alessandro / Tamburini, Fabio (eds.): *Proceedings of the Fifth Italian Conference on Computational Linguistics CLiC-it 2018. 10-12 December 2018, Torino* , Torino: Accademia University Press 311-317.

Prifti, Elton / Schweickard, Wolfgang / Selig, Maria / Tittel, Sabine (2022): "Sprachdatenbasierte Modellierung von Wissensnetzen in der mittelalterlichen Romania (ALMA): Projektskizze", in: *Zeitschrift für romanische Philologie* , 139, 2: 301-322.

Tittel, Sabine (2023): "Ceci n'est pas un dictionnaire. Adding and Extending Lexicographical Data of Medieval Romance Languages to and through a Multilingual Lexico-Ontological Project", in: Medved', Marek / Měchura, Michal / Tiberius, Carole / Kosem, Iztok / Kallas, Jelena / Jakubíček, Miloš (eds.): *Electronic lexicography in the 21st century (eLex 2023): Invisible Lexicography. Proceedings of the eLex 2023 conference. Brno, 27–29 June 2023* . Brno: Lexical Computing CZ s.r.o. 39-52.

Tittel, Sabine / Gillis-Webber, Frances / Nannini, Alessandro A. (2020): "Towards an ontology based on Hallig-Wartburg's «Begriffssystem» for Historical Linguistic Linked Data", in: Ionov, Maxim / McCrae, John P. / Chiarcos, Christian / Declerck, Thierry / Bosque-Gil, Julia / Gracia, Jorge (eds.): *Proceedings of the 7th Workshop on Linked Data in Linguistics (LDL-2020)* . Marseille: European Language Resources Association 1-10.